

# Exploración y análisis de datos

Febrero 2023



red.es



*"El FSE invierte en tu futuro"*  
**Fondo Social Europeo**

# Índice

1. Estadística descriptiva
2. Conceptos básicos de probabilidad
  - 2.1 Teoría de la probabilidad
  - 2.2 Interpretación Bayesiana
3. Variables aleatorias discretas
4. Reglas básicas de probabilidad
5. Variables aleatorias continuas
6. Operador esperanza
7. Aplicaciones de probabilidad al enfoque Bayesiano
8. Algunas distribuciones discretas comunes
9. Algunas distribuciones continuas comunes

Exploración y análisis de datos

# Estadística descriptiva

## Estadística descriptiva

### Moda, media aritmética y mediana

#### Media

(Promedio) Suma de datos dividido entre la cantidad de los mismos.

$$\bar{x} = \frac{\sum x}{N}$$

#### Moda

Dato que mas se repite. Si son dos es bimodal, si son 3 es trimodal.




#### Mediana

Dato central. Si son dos se saca la media de estos.

$$med_x$$

# Estadística descriptiva

## Moda, media aritmética y mediana



# Estadística descriptiva


## Varianza y desviación estándar

### VARIANZA

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N}$$

- $X$  → Variable
- $x_i$  → Observación número  $i$  de la variable  $X$ .
- $N$  → Número de observaciones.
- $\bar{X}$  → Es la media de la variable  $X$ .

Es una medida de dispersión que representa la variabilidad de una serie de datos respecto a su media.



# Estadística descriptiva


## Varianza y desviación estándar

### DESVIACIÓN ESTÁNDAR

$$\sigma = \sqrt{\frac{\sum_1^N (x_i - \bar{X})^2}{N}}$$

- $X$  → Variable
- $N$  → Número de observaciones.
- $x_i$  → Observación número  $i$  de la variable  $X$ .
- $\bar{X}$  → Es la media de la variable  $X$ .

También conocida como desviación típica  $\sigma$  es una medida que ofrece información sobre la dispersión media de una variable.



# Conceptos básicos de probabilidad



# Conceptos básicos de probabilidad

## Teoría de la probabilidad

“La probabilidad de que una moneda saque cara es 0.5”.

Interpretaciones:

- **Frecuentista:** Las probabilidades representan frecuencias de eventos a largo plazo. “Si lanzamos la moneda muchas veces, esperamos obtener cara en la mitad de las veces.”
- **Bayesiana:** La probabilidad se utiliza para cuantificar nuestra incertidumbre sobre algo. Más relacionado con información que con ensayos repetidos. “Hay igual probabilidad de obtener cara que cruz en la siguiente tirada.”

Probability theory is nothing but common sense reduced to calculation. — Pierre Laplace, 1812

# Conceptos básicos de probabilidad

## Interp. Bayesiana

Puede modelar la incertidumbre de eventos que no tienen frecuencias a largo plazo.

- Calcular la probabilidad de que un mensaje que recibir en el correo sea spam.
- Calcular la distribución de probabilidad de la localización de un objetivo en una pantalla radar.

# Variables aleatorias discretas

# Variables aleatorias discretas

## Definiciones básicas

*Problema binario:*

- $p(A)$ : Probabilidad de que el evento A sea verdad.
- $0 \leq p(A) \leq 1$
- $p(\bar{A}) = 1 - p(A)$
- $p()$ : Función de masa de probabilidad



*Variable aleatoria discreta: X*

- $p(X = x)$ : Probabilidad de que el evento X sea igual x.

$$\sum_{x \in \mathcal{X}} p(x) = 1.$$

# Variables aleatorias discretas

## Ejemplos



# Reglas básicas de probabilidad

# Reglas básicas de probabilidad

## Distribuciones conjuntas y marginales

$$\begin{aligned} p(A \vee B) &= p(A) + p(B) - p(A \wedge B) \\ &= p(A) + p(B) \end{aligned}$$

Probabilidad conjunta:

$$p(A, B) = p(A \wedge B) = p(A|B)p(B)$$

$$p(X_{1:D}) = p(X_1)p(X_2|X_1)p(X_3|X_2, X_1)p(X_4|X_1, X_2, X_3) \dots p(X_D|X_{1:D-1})$$

Distribución marginal:

$$p(A) = \sum_b p(A, B) = \sum_b p(A|B = b)p(B = b)$$

# Reglas básicas de probabilidad

## Probabilidad condicional y regla de Bayes

Probabilidad condicional:

$$p(A|B) = \frac{p(A, B)}{p(B)} \text{ if } p(B) > 0$$

Regla de Bayes:

$$p(X = x|Y = y) = \frac{p(X = x, Y = y)}{p(Y = y)} = \frac{p(X = x)p(Y = y|X = x)}{\sum_{x'} p(X = x')p(Y = y|X = x')}$$



## Ejemplo práctico

**Te vas a hacer un test (x) para cáncer de pecho (y), específicamente una mamografía.**

- Si el test es positivo, cuál es la probabilidad de tener cáncer?

Depende de cómo de fiable sea el test.

Sensibilidad del test: 80%

$$p(x = 1|y = 1) = 0.8$$

- Podrías pensar que tienes el 80% de probabilidad de tener cáncer pero esto no es verdad!

No puedes ignorar

- la probabilidad a priori de tener cáncer de pecho.

$$p(y = 1) = 0.004$$

- La probabilidad de un falso positivo / falsa alarma

$$p(x = 1|y = 0) = 0.1$$

$$\begin{aligned} p(y = 1|x = 1) &= \frac{p(x = 1|y = 1)p(y = 1)}{p(x = 1|y = 1)p(y = 1) + p(x = 1|y = 0)p(y = 0)} \\ &= \frac{0.8 \times 0.004}{0.8 \times 0.004 + 0.1 \times 0.996} = 0.031 \end{aligned}$$



# Reglas básicas de probabilidad

## Independencia incondicional

Variables aleatorias independientes  
incondicionalmente

$$X \perp Y \iff p(X, Y) = p(X)p(Y)$$

**Theorem 2.2.1.**  $X \perp Y|Z$  iff there exist function  $g$  and  $h$  such that

$$p(x, y|z) = g(x, z)h(y, z)$$

for all  $x, y, z$  such that  $p(z) > 0$ .

Útil para construir modelos probabilísticos: Clasificador Naive Bayes, modelos de Markov, modelos gráficos,...

# Variables aleatorias continuas

## Variables aleatorias continuas

### Funciones de distribución y de densidad de probabilidad

$F(q) = p(X \leq q)$ : Función de distribución acumulada de  $X$  (cdf)

- Monótona creciente
- $p(a < X \leq b) = F(b) - F(a)$

$f(x) = \frac{d}{dx} F(x)$ : Función de densidad de probabilidad (pdf)


- Probabilidad de que una variable continua esté comprendida en un intervalo finito:

$$P(a < X \leq b) = \int_a^b f(x)dx$$

## Variables aleatorias continuas

### Propiedades de la función de densidad de probabilidad

$$\begin{aligned} p(x) &\geq 0 \\ \int_{-\infty}^{\infty} p(x) dx &= 1 \end{aligned}$$



# Variables aleatorias continuas

## Función cuantil, media y varianza

- $F^{-1}(\alpha)$ : Función de distribución acumulada inversa. **Función cuantil.**

Es el valor de  $x_\alpha$  tal que  $P(X \leq x_\alpha) = \alpha$

- **Mediana:**  $F^{-1}(0.5)$ , con la mitad de la masa de probabilidad a la izquierda y la otra mitad a la derecha.

- **Media:**

$$\mathbb{E}[X] \triangleq \int_{\mathcal{X}} x p(x) dx$$

- **Varianza:**

$$\begin{aligned} \text{var}[X] &\triangleq \mathbb{E}[(X - \mu)^2] = \int (x - \mu)^2 p(x) dx \\ &= \int x^2 p(x) dx + \mu^2 \int p(x) dx - 2\mu \int x p(x) dx = \mathbb{E}[X^2] - \mu^2 \end{aligned}$$

- **Desviación estándar:**

$$\text{std}[X] \triangleq \sqrt{\text{var}[X]}$$

$$\mathbb{E}[X^2] = \mu^2 + \sigma^2$$

# Operador esperanza

# Operador esperanza

## Variables discretas y continuas

$$\mathbb{E}[f] = \int p(x) f(x) \, dx.$$

$$\mathbb{E}[f] = \sum_x p(x) f(x)$$



# Operador esperanza

## Varianza y covarianza

- **Varianza:** Proporciona una medida de cuanta variabilidad hay en  $x$  alrededor de su valor medio.

$$\text{var}[x] = \mathbb{E}[x^2] - \mathbb{E}[x]^2$$

- **Covarianza:** Extiende el concepto a dos variables aleatorias y expresa hasta qué punto  $x$  e  $y$  varían juntas. Si son independientes, la covarianza es nula.

$$\begin{aligned}\text{cov}[x, y] &= \mathbb{E}_{x,y} [\{x - \mathbb{E}[x]\} \{y - \mathbb{E}[y]\}] \\ &= \mathbb{E}_{x,y}[xy] - \mathbb{E}[x]\mathbb{E}[y]\end{aligned}$$

## Operador esperanza

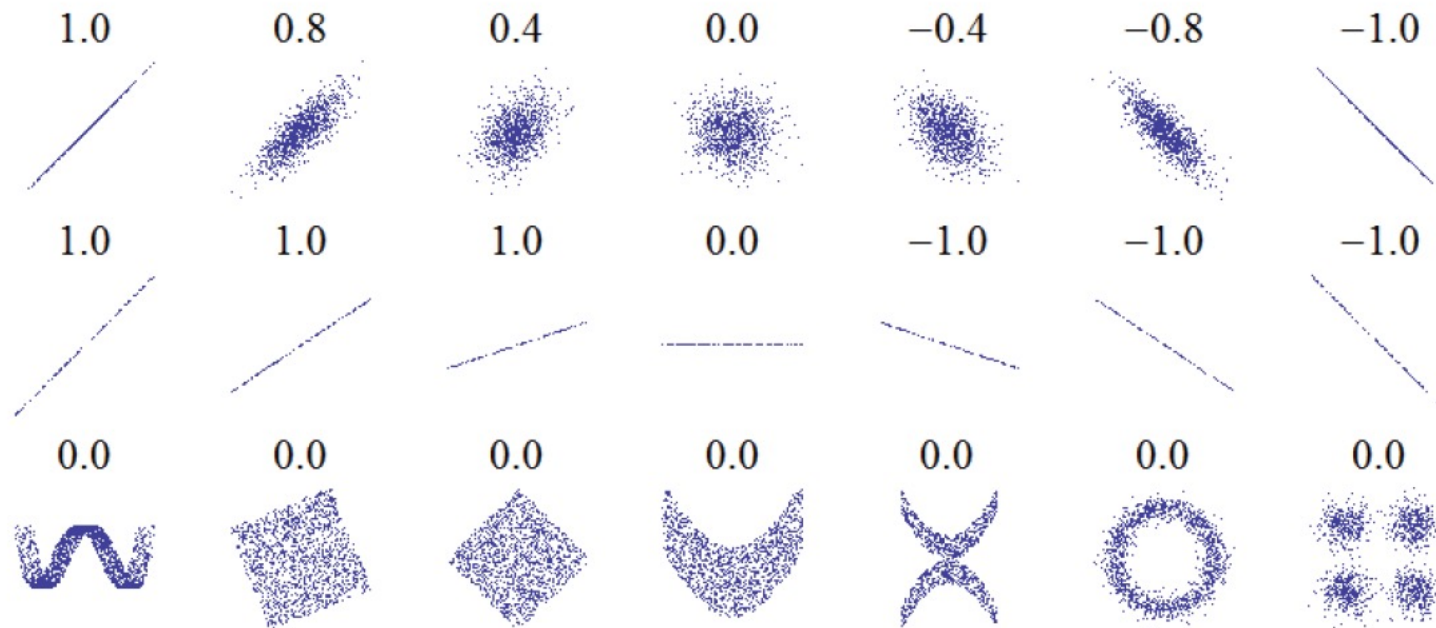
### Coeficiente de correlación (Pearson) y matriz de correlación

$$\text{corr}[X, Y] \triangleq \frac{\text{cov}[X, Y]}{\sqrt{\text{var}[X] \text{var}[Y]}}$$

$$\mathbf{R} = \begin{pmatrix} \text{corr}[X_1, X_1] & \text{corr}[X_1, X_2] & \cdots & \text{corr}[X_1, X_d] \\ \vdots & \vdots & \ddots & \vdots \\ \text{corr}[X_d, X_1] & \text{corr}[X_d, X_2] & \cdots & \text{corr}[X_d, X_d] \end{pmatrix}$$

## Operador esperanza

### Coeficiente de correlación (Pearson) y matriz de correlación



El coeficiente de correlación refleja el ruido y la dirección de la relación lineal, pero no la pendiente de esa relación ni aspectos no lineales.

Incorrelación no implica independencia.

## Operador esperanza

### Coeficiente de correlación (Pearson) y matriz de correlación

	date	weight	resp_1	resp_2	resp_3	resp_4	resp	feature_0	feature_1	feature_2
date	1.00	0.02	0.02	0.01	0.01	-0.02	-0.03	0.01	-0.05	-0.01
weight	0.02	1.00	-0.01	-0.01	-0.02	-0.02	-0.02	-0.02	-0.05	0.06
resp_1	0.02	-0.01	1.00	0.92	0.80	0.49	0.58	0.04	0.03	0.02
resp_2	0.01	-0.01	0.92	1.00	0.91	0.55	0.68	0.04	0.04	0.01
resp_3	0.01	-0.02	0.80	0.91	1.00	0.77	0.80	0.03	0.04	0.01
resp_4	-0.02	-0.02	0.49	0.55	0.77	1.00	0.95	-0.06	0.00	-0.04
resp	-0.03	-0.02	0.58	0.68	0.80	0.95	1.00	-0.06	0.00	-0.04
feature_0	0.01	-0.02	0.04	0.04	0.03	-0.06	-0.06	1.00	0.03	0.03
feature_1	-0.05	-0.05	0.03	0.04	0.04	0.00	0.00	0.03	1.00	0.84
feature_2	-0.01	0.06	0.02	0.01	0.01	-0.04	-0.04	0.03	0.84	1.00

# Aplicaciones de la probabilidad al enfoque Bayesiano

# Aplicaciones de la probabilidad al enfoque Bayesiano

## Deshielo del Ártico

- No es un evento que se repita (frecuentista).
- Tenemos una idea de cómo de rápido el hielo polar se está derritiendo.
- Si recibimos información de un satélite sobre nuevos diagnósticos, podríamos revisar nuestra opinión sobre cómo de rápido se produce el deshielo.
- Nuestra evaluación del problema provocará nuevas acciones sobre por ejemplo la emisión de gases.

**Queremos cuantificar la incertidumbre y hacer revisiones precisas cuando tenemos nuevas evidencias.**



# Aplicaciones de la probabilidad al enfoque Bayesiano

## Enfoque Bayesiano en Machine Learning

Usar la teoría de la probabilidad para describir la incertidumbre en los parámetros del modelo,  $w$ , o en la elección del modelo en sí.

- Distribución de **probabilidad a priori**:  $p(w)$   
Captura nuestras suposiciones sobre  $w$  antes de observar los datos.
- El efecto de observar los datos se expresa a través de la probabilidad condicional,  $p(D|w)$ . Es una función de los parámetros y se llama **likelihood function**. Expresa cómo de probable es el conjunto de datos para diferentes configuraciones de los parámetros.
- Así podemos evaluar la incertidumbre en los parámetros,  $w$ , después de observar los datos en forma de probabilidad a posteriori,  $p(w|D)$ .

$$p(w|D) = \frac{p(D|w)p(w)}{p(D)} \longrightarrow p(D) = \int p(D|w)p(w) dw$$

# Aplicaciones de la probabilidad al enfoque Bayesiano

## Enfoque Bayesiano en Machine Learning

Usar la teoría de la probabilidad para describir la incertidumbre en los parámetros del modelo,  $w$ , o en la elección del modelo en sí.

$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$



# Aplicaciones de la probabilidad al enfoque Bayesiano

## Enfoque Bayesiano en Machine Learning

Interpretación frecuentista:  $\mathbf{w}$  se considera un vector de parámetros fijos cuyo valor se determina a través de un estimador y los errores se obtienen considerando la distribución **de posibles conjuntos de datos**  $D$ .

Interpretación Bayesiana: **Sólo hay un conjunto de datos**  $D$  (el observado) y la incertidumbre en los parámetros se expresa a través de una **distribución de probabilidad sobre  $\mathbf{w}$** .

# Aplicaciones de la probabilidad al enfoque Bayesiano

## Enfoque Bayesiano en Machine Learning

**Elegimos los valores de los parámetros que optimizan un criterio.**

Estimador “Maximum likelihood”: se seleccionan los parámetros  $\mathbf{w}$  que maximizan la función likelihood,  $p(D|\mathbf{w})$

Esto corresponde a elegir los valores de  $w$  para los cuales la probabilidad de los datos observados es maximizada.

Función error: ***Negative log likelihood***, es monótona decreciente.  
Maximizar la *likelihood* es equivalente a minimizar el error.

# Algunas distribuciones discretas comunes

## Algunas distribuciones discretas

### Bernoulli

**Variables aleatorias binarias.**

Ejemplo: lanzar una moneda y obtener cara

$$p(x = 1|\mu) = \mu \qquad p(x = 0|\mu) = 1 - \mu$$

$$\text{Bern}(x|\mu) = \mu^x(1 - \mu)^{1-x}$$

$$\begin{aligned} \mathbb{E}[x] &= \mu \\ \text{var}[x] &= \mu(1 - \mu) \end{aligned}$$

## Algunas distribuciones discretas

### Bernoulli

**Aplicación en ML, asumiendo que las observaciones son independientes e idénticamente distribuidas.**

$$p(\mathcal{D}|\mu) = \prod_{n=1}^N p(x_n|\mu) = \prod_{n=1}^N \mu^{x_n} (1 - \mu)^{1-x_n}$$

## Algunas distribuciones discretas

### Binomial

**Cuando el tamaño del conjunto de datos es N.**  
Ejemplo: Lanzar N monedas y obtener m caras.


$$\text{Bin}(m|N, \mu) = \binom{N}{m} \mu^m (1 - \mu)^{N-m}$$

$$\binom{N}{m} \equiv \frac{N!}{(N-m)!m!}$$

## Algunas distribuciones discretas

### Binomial

Ejemplo:  $N=10$  y  $\mu=0.25$



## Algunas distribuciones discretas

### Multinomial

**Cuando el tamaño del conjunto de datos es  $N$  y la variable discreta puede tomar uno de  $K$  estados posibles mutuamente exclusivos.**

$$\mu_k = P(x_k = 1)$$

Ejemplo: lanzar  $N$  veces un dado

*One-hot encoding*

$$\mathbf{x} = (0, 0, 1, 0, 0, 0)^T$$

$$\sum_{k=1}^K x_k = 1$$

$$p(\mathbf{x}|\boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k}$$

$$\sum_k \mu_k = 1$$

$$\mu_k \geq 0$$



## Algunas distribuciones discretas

### Multinomial

#### Otra notación

$$\text{Mu}(\mathbf{x}|n, \boldsymbol{\theta}) \triangleq \binom{n}{x_1 \dots x_K} \prod_{j=1}^K \theta_j^{x_j}$$

**vs**

$$\text{Mu}(\mathbf{x}|1, \boldsymbol{\theta}) = \prod_{j=1}^K \theta_j^{\mathbb{I}(x_j=1)}$$

$$\binom{n}{x_1 \dots x_K} \triangleq \frac{n!}{x_1! x_2! \dots x_K!}$$

$x_j$  es las veces que aparece la cara  $j$  del dado

## Algunas distribuciones discretas

### Poisson



Para modelar cuentas de eventos raros como accidentes de tráfico.

$$X \in \{0, 1, 2, \dots\}$$

$$\text{Poi}(x|\lambda) = e^{-\lambda} \frac{\lambda^x}{x!} \quad \lambda > 0$$

# Algunas distribuciones discretas

## Poisson



# Algunas distribuciones continuas comunes

## Algunas distribuciones continuas

### Gaussian

**De una variable única o multidimensional**

Parámetros: media y varianza/covarianza

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}$$

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\}$$

## Algunas distribuciones continuas

### Gaussian

#### **Teorema del límite central**

Sujeto a ciertas condiciones, la suma de un conjunto de variables aleatorias, que también es en sí una variable aleatoria, tiene una distribución que se convierte cada vez más en Gaussiana cuando el número de términos en la suma aumenta.

## Algunas distribuciones continuas

### T-student

$$\mathcal{T}(x|\mu, \sigma^2, \nu) \propto \left[ 1 + \frac{1}{\nu} \left( \frac{x - \mu}{\sigma} \right)^2 \right]^{-\left(\frac{\nu+1}{2}\right)}$$

$$\text{mean} = \mu, \text{mode} = \mu, \text{var} = \frac{\nu\sigma^2}{(\nu - 2)}$$

## Algunas distribuciones continuas

### Laplace

Parámetros: localización,  $\mu$  y escala,  $b$ .

$$\text{Lap}(x|\mu, b) \triangleq \frac{1}{2b} \exp\left(-\frac{|x - \mu|}{b}\right)$$



$$\text{mean} = \mu, \text{ mode} = \mu, \text{ var} = 2b^2$$



# Algunas distribuciones continuas

## Gaussiana, T-student y Laplace

La Gaussiana es más sensible a *outliers*.



## Algunas distribuciones continuas

### Gamma

#### Para datos reales positivos

Parámetros: forma,  $\alpha$ , y escala,  $\lambda$ . Mayores que 0.

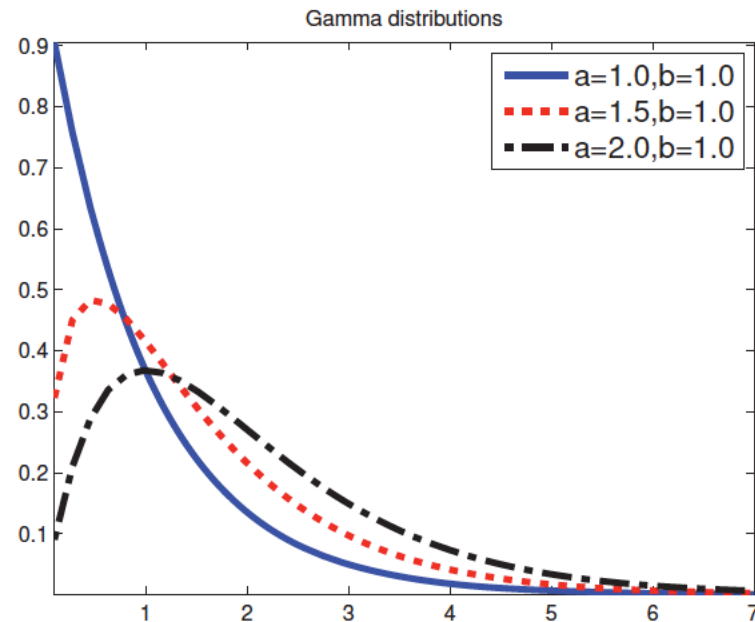
$$\text{Ga}(T|\text{shape} = a, \text{rate} = b) \triangleq \frac{b^a}{\Gamma(a)} T^{a-1} e^{-Tb}$$

$$\Gamma(x) \triangleq \int_0^{\infty} u^{x-1} e^{-u} du$$

$$\text{mean} = \frac{a}{b}, \text{ mode} = \frac{a-1}{b}, \text{ var} = \frac{a}{b^2}$$

# Algunas distribuciones continuas

## Gamma



## Algunas distribuciones continuas

### Beta

Parámetros: a y b. Mayores que 0.


$$\text{Beta}(x|a, b) = \frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1}$$

$$B(a, b) \triangleq \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

$$\text{mean} = \frac{a}{a+b}, \text{ mode} = \frac{a-1}{a+b-2}, \text{ var} = \frac{ab}{(a+b)^2(a+b+1)}$$

# Algunas distribuciones continuas

## Beta




## Algunas distribuciones continuas

### Dirichlet

**Generalización multivariable de la distribución Beta.**  
Simplex de probabilidad.

$$S_K = \{\mathbf{x} : 0 \leq x_k \leq 1, \sum_{k=1}^K x_k = 1\}$$




$$\text{Dir}(\mathbf{x}|\boldsymbol{\alpha}) \triangleq \frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K x_k^{\alpha_k-1} \mathbb{I}(\mathbf{x} \in S_K)$$



## Algunas distribuciones continuas

### Dirichlet

$$\alpha_k = 0.1, 1 \text{ y } 10$$



## Supuesto básico en ML

los datos = señal + ruido (Gaussiana)  
es decir,  $y = f(x) + \epsilon$  donde  $\epsilon$  es el 'error irreducible'

Aunque el ruido ( $\epsilon$ ) es aleatorio, si se tiene un número grande de muestras finalmente se aproxima a una **distribución Gaussiana**.

En matemáticas eso se llama el “**teorema del límite central**”



## Práctica

Practiquemos sobre estadística y conceptos básicos de probabilidad.

**Notebook:**

**5. Estadística descriptiva y probabilidad**

**Duración estimada: 1h**



## Contacto

Correo: [a.cobo.aguilera@gmail.com](mailto:a.cobo.aguilera@gmail.com)

LinkedIn: [Aurora Cobo Aguilera](#)

GitHub: [AuroraCoboAguilera](#)

Google Scholar: [Aurora Cobo Aguilera](#)





red.es



*"El FSE invierte en tu futuro"*

**Fondo Social Europeo**

